Patrones invisibles: información, incertidumbre y movilidad urbana

Documento de soporte del Proyecto Retador · Consultoría analítica para UrbanMove

NYC Taxi Trip Duration · 1.458.644 viajes · enero a junio de 2016

Equipo y reparto de bloques

Integrante	Código	Bloque técnico
Ricardo Borja	0000333542	Rol 1 · Incertidumbre e información
Gabriel Murillo	0000285035	Rol 2 · Segmentación por partición
Samuel Robayo	0000329495	Rol 3 · Mezclas y variables latentes
Maria Andrea Torres	0000334682	Rol 4 · Negocio y selección de datos

Enlaces

Recurso	Enlace
Dataset en Kaggle	https://www.kaggle.com/c/nyc-taxi-trip-duration/data
Shapefile de zonas de taxi de NYC	https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page
Repositorio del equipo	https://github.com/rborja79/aprendizajenosupervisado

Justificación de la estrategia de muestreo y filtrado

El archivo tiene 1.458.644 viajes y no todos los cálculos cuestan lo mismo, así que no se tratan igual.

Las entropías, la información mutua y la divergencia KL se calculan sobre la base de trabajo completa después de los filtros de calidad: 1.431.173 viajes. Son tablas de frecuencias: el costo es bajo y muestrear solo agregaría error. No se usa una muestra, pero tampoco el archivo crudo, porque los registros filtrados distorsionan justamente las variables que se miden aquí.

El clustering y la mezcla gaussiana usan una muestra aleatoria de 50.000 viajes con semilla 2026. La silueta es de orden n al cuadrado y DBSCAN sobre 1,4 millones de puntos no cabe en memoria. Con ese tamaño el error estándar de una proporción es menor a 0,25 puntos porcentuales, suficiente para decidir dónde ubicar conductores.

Se descarta el 1,88 % de los registros por cinco reglas de calidad y pertinencia analítica. No se eliminan viajes atípicos incómodos: se eliminan registros implausibles o poco informativos para este análisis. El detalle regla por regla está en la sección siguiente.

Detalle de los filtros

Regla	Criterio
Duración	fuera de 1 a 120 minutos
Distancia	fuera de 0,2 a 60 km
Velocidad	fuera de 2 a 90 km/h
Pasajeros	fuera de 1 a 6
Coordenadas	fuera de las zonas oficiales de NYC

Ninguna regla elimina más del 1,2 % y cada una se cuenta por separado para poder defenderla una por una. La palabra no es *imposible*: un recorrido de menos de 200 m en línea recta puede ser una ida y vuelta real, y uno por debajo de 2 km/h puede ser un viaje con espera larga. Lo que ocurre es que ninguno informa sobre el patrón espacial ni sobre la velocidad de circulación, que es lo que se está midiendo. Los extremos que sí son imposibles, como un viaje de 58.771 minutos o uno a 9.274 km/h, caen por estas mismas reglas.

Resultados por bloque

Rol 1 · Incertidumbre e información, en bits, sobre la base de trabajo (1.431.173 viajes)

Métrica	Valor	Lectura
H(zona de recogida)	5,7221 bits	53 zonas efectivas de 237
H máxima posible	7,89 bits	si las 237 zonas tuvieran la misma demanda
H(zona | hora)	5,6383 bits	50 zonas efectivas conociendo la hora
I(hora ; zona de recogida)	0,0838 bits	**1,46 % de H(zona de recogida)**
I(hora ; zona de destino)	0,1126 bits	**1,83 % de H(zona de destino)**
I(zona origen ; zona destino)	0,4726 bits	7,70 % de H(zona de destino)
I(distrito origen ; distrito destino)	0,0673 bits	10,16 % de H(**distrito** de destino) = 0,66 bits
I(día de la semana ; destino)	0,0111 bits	0,18 % de H(zona de destino)
KL(laboral || fin de semana)	0,0553 bits	inversa: 0,0596 bits
KL(no festivo || festivo)	0,0241 bits	los festivos se parecen a un día normal
KL(hora pico || madrugada)	0,3801 bits	inversa: 0,4398 bits
Entropía cruzada H(laboral, fds)	5,73 bits	H(p) + KL(p||q)
Brecha de Jensen en duración	0,2532 **nats** (0,3652 bits)	media geométrica 10,8 min contra aritmética 14,0

Estimador. H, H(·|·) e I se calculan con el estimador empírico de frecuencias (sin suavizado) sobre **una sola tabla conjunta**, de la que se derivan las marginales. Así I(X;Y) = H(Y) − H(Y|X) = H(X) + H(Y) − H(X,Y) se cumple de forma exacta; el cuaderno incluye la comprobación. El suavizado de Laplace se reserva para la divergencia KL, donde un cero en q daría infinito. Con 1,4 millones de observaciones suavizar las entropías no está justificado y además sesga: aplicar Laplace fila por fila inflaba H(zona|hora) y con ello *subestimaba* la información mutua.

Dos medidas distintas. La hora explica el **1,46 %** de la incertidumbre sobre la **zona de recogida** (0,0838 de 5,7221 bits) y el **1,83 %** sobre la **zona de destino** (0,1126 de 6,1383 bits). Son dos preguntas distintas: dónde aparecerá el próximo pasajero y a dónde va a querer ir. Las dos se responden igual: el reloj casi no informa.

Cuidado al comparar los porcentajes entre filas. La entropía de la zona de destino es **6,1383 bits**. El distrito de recogida explica el **10,16 %** de la incertidumbre del *distrito* de destino, cuya H es apenas 0,6621 bits, y la zona de recogida explica el **7,70 %** de la

incertidumbre de la *zona* de destino. Como cada fila divide por una H(Y) distinta, el porcentaje invierte el orden: en cantidad de información la zona aporta **0,4726 bits** frente a **0,0673 bits** del distrito, siete veces más. Para decidir dónde poner conductores mandan los bits, no el porcentaje.

La brecha de Jensen está en nats, no en bits, porque se calcula con logaritmo natural. Se reporta en las dos escalas para que no se confunda con las entropías de esta misma tabla.

Rol 2 · Segmentación por partición, muestra de 50.000 viajes

Método	Hiperparámetros	Validación	Resultado
K-means	k = 4, n_init = 10	silueta 0,496 · DB 0,494 · CH 15.533	Union Sq 43,8 %, Upper East Side South 50,8 %, LaGuardia 3,1 %, JFK 2,3 %
K-means (descartado)	k = 2	silueta 0,808	solo separa Manhattan de los aeropuertos: sin uso operativo
DBSCAN	eps = 393 m (codo), min_samples = 50	silueta 0,333 · DB 0,426	7 núcleos densos y 2,40 % de ruido (43 % Queens, 38 % Brooklyn)

La otra regla posible para eps es el percentil 95 de la curva de k-distancia, que da eps = 274 m, 5 núcleos densos y 4,19 % de ruido, contra 393 m, 7 núcleos y 2,40 % de la regla del codo que sí usamos. La conclusión cualitativa aguanta las dos reglas. La corrida con el percentil 95 está en el cuaderno.

Comparación estricta. La tabla de arriba evalúa cada método sobre el subconjunto que le corresponde por su propia definición, lo que favorece a DBSCAN porque le quita el ruido de encima. Repetida sobre los mismos 10.000 puntos de señal, K-means obtiene silueta 0,505 y Davies-Bouldin 0,453, contra 0,322 y 0,432 de DBSCAN. La lectura no cambia: K-means separa mejor y DBSCAN aporta lo que K-means no puede dar, la identificación del 2,40 % que no pertenece a ningún núcleo.

Rol 3 · Mezcla gaussiana con EM propio, muestra de 50.000 viajes

Parámetro final	Valor
Variables	log duración, log distancia, velocidad, seno y coseno de la hora
Componentes	K = 3 (codo de la curva del BIC; ver la nota de abajo)
Pesos π	33,52 % · 39,96 % · 26,52 %, que suman 100,00 %
Reparto de la muestra por asignación dura	33,36 % · 40,28 % · 26,36 %, que suman 100,00 %
Iteraciones hasta converger	75 con kmeans++ · 71 con inicialización aleatoria
Criterio de parada	$\|\Delta$ log-verosimilitud$\|$ < 1e-6, máximo 300 iteraciones
Log-verosimilitud media	–3,4590 (sklearn de control: –3,4608)
Certeza media de pertenencia	0,978 · 1,25 % de viajes por debajo de 0,6 · 93,21 % por encima de 0,9

Parámetros finales por componente, en unidades originales

Comp.	π	μ log dur.	μ log dist.	μ vel.	σ log dur.	σ log dist.	σ vel.
0	33,52 %	2,4733	0,3813	7,70	0,5934	0,6182	1,95
1	39,96 %	2,3123	0,8228	13,67	0,7004	0,7121	1,98
2	26,52 %	2,3858	1,4588	24,53	0,8831	0,9366	6,86

Las medias y desviaciones están deshechas del escalado (μ con el *scaler* inverso, Σ con $\Sigma_{orig} = D\,\Sigma\,D$ y D = diag de las escalas). Los ángulos de la hora se omiten en esta tabla por legibilidad; las matrices de covarianza completas, incluidos seno y coseno de la hora, están en el cuaderno. Los pesos suman 100,00 %.

Perfil	Peso	Duración	Distancia	Velocidad	Hora típica	% fin de semana	Lectura
0	33,4 %	12,0 min	1,5 km	8,0 km/h	18:00	20,7 %	corto y atascado: Midtown en pico
1	40,3 %	10,0 min	2,2 km	13,5 km/h	21:00	30,6 %	el viaje urbano corriente
2	26,4 %	11,8 min	4,4 km	22,4 km/h	22:00	36,0 %	largo y fluido: noche y aeropuertos

Duración y distancia son medianas: exp de la media de un logaritmo es la media geométrica, que en una lognormal es la mediana. Es el mismo punto que señala la brecha de Jensen del Rol 1: reportarle a UrbanMove el promedio de duración sobreestima el viaje típico.

Por qué K = 3, y por qué no es el mínimo del BIC

El BIC no tiene mínimo interior en el rango explorado. No es cierto que baje de forma monótona: sube de K = 3 a K = 4, una desmejora del 5,7 %. Pero tampoco se da la vuelta: el valor más bajo cae en el borde superior, K = 8. Un mínimo en el borde no es un mínimo, es la señal de dónde se dejó de buscar. Cuando el BIC sigue cayendo sin estabilizarse lo habitual es que el modelo esté mal especificado: los datos no son gaussianos y el EM gasta cada componente nueva en parchear la forma de la densidad, no en encontrar grupos. En este caso hay una causa concreta, el seno y el coseno de la hora solo toman 24 valores y una componente puede colapsar sobre uno. **Por eso K = 3 se elige por el codo de la curva y se sostiene por parsimonia, estabilidad e interpretabilidad, no como mínimo del BIC.** K = 3 es además el único mínimo local del rango, es donde las dos inicializaciones coinciden en el mismo óptimo y es donde los perfiles siguen distinguiendo tipos de viaje. El repunte de K = 4 es con toda probabilidad un óptimo local: el barrido usa n_init = 3.

K	2	3	4	5	6	7	8
BIC	438.906	346.750	366.395	298.045	287.723	235.003	205.684

Sensibilidad a la inicialización y a los mínimos locales

Con K = 3, kmeans++ llega al mismo óptimo en las tres semillas (–3,442 de mínimo y de máximo, sobre el submuestreo de 15.000 viajes que usa esta prueba). Con inicialización aleatoria una de las tres queda atrapada en –3,606 frente a –3,442 de las otras dos. Con K = 6 se dispersan las dos inicializaciones, que es justo lo que se espera cuando sobran componentes. Las cifras de esta prueba no son comparables con la log-verosimilitud del ajuste principal: esa se calcula sobre los 50.000 viajes y esta sobre un submuestreo de 15.000.

Sensibilidad al conjunto de variables: qué pasa si se quita la velocidad

La velocidad es distancia dividida por duración, así que es función determinista de las otras dos variables y deja la covarianza mal condicionada: de ahí la regularización 1e-6 del EM. La objeción es legítima, así que antes de quitarla lo medimos. **Quitarla empeora el modelo.** Sin velocidad el codo se desplaza a K = 5, la certeza media de pertenencia sube a 0,9999 y no queda ni un viaje ambiguo por debajo de 0,6, lo que no es buena separación sino colapso. El diagnóstico es directo: la dispersión mediana de los ángulos horarios cae de 0,685 a 0,217 mientras la de log-duración se queda igual (0,700 contra 0,728). Es decir, sin velocidad las componentes se separan por el reloj y no por el tipo de viaje, y los cinco perfiles resultantes tienen duraciones de 9 a 12 minutos y distancias de 2 a 3 km, indistinguibles entre sí. **La variable que degenera no es la velocidad: son los ángulos horarios**, que solo toman 24 valores; mientras la velocidad está dentro, ella sostiene la señal de congestión y esa degeneración no domina. Se reporta el modelo de cinco variables y la prueba queda en el cuaderno.

Tres recomendaciones para UrbanMove

1. Posicionar por zona, dimensionar por hora.

La hora explica el **1,46 %** de la incertidumbre sobre dónde saldrá el próximo viaje (0,0838 bits de los 5,7221 de H(zona de recogida)) y el **1,83 %** de la del destino, pero 10 zonas concentran entre el 35 % y el 42 % de la demanda en cualquier franja. La recomendación es base estable de conductores en esas zonas y mover con la hora el volumen. **El volumen se dimensiona por viajes por hora, no por totales de franja**, porque las franjas duran distinto: la madrugada (0–5 h) mueve 167.208 viajes en 6 horas, es decir 27.868 por hora, contra 72.972 por hora de la tarde (12–18 h, 510.802 viajes en 7 horas). Eso es el **38 % del ritmo horario de la tarde**, no un tercio. Si se dimensiona por la hora de máxima demanda la brecha es mayor: 89.076 viajes a las 18 h contra 14.612 a las 5 a.m., un 16 %. La franja más intensa por hora no es la tarde sino la noche (19–23 h): 80.386 viajes por hora. Única excepción geográfica, la madrugada, cuando la zona dominante pasa a ser East Village y sus 10 zonas concentran el 41,8 %.

2. **Ponderar el tiempo en la tarifa de las horas congestionadas.**

   El 30,1 % de los viajes va por debajo de 10 km/h y gasta 7,80 minutos por kilómetro contra 3,86 del resto: **aproximadamente el doble, 2,02 veces**. En día laboral, entre las 8 y las 16 horas más del 40 % de los viajes está en esa condición, con un pico de 51,7 % a las 11; el fin de semana no pasa del 31,1 %. El perfil 0 de la mezcla, que es el 33,4 % de los viajes, es justamente ese. Una tarifa que solo cobre distancia castiga al conductor en las horas de mayor demanda.

3. **Reasignar el fin de semana y atender el borde bajo demanda.**

   East Village gana 2,05 puntos porcentuales y Lower East Side 1,49, mientras Midtown Center cae de 4,06 % a 2,66 %, una pérdida relativa del 34 %. De ahí sale el orden de magnitud: mover cerca de un tercio de la flota *de Midtown* hacia el sur el fin de semana. Es la caída relativa de esa zona, no una proporción de la flota total, y se propone como punto de partida y no como óptimo calculado. El 2,40 % de viajes que DBSCAN marca como ruido no debe tener flota fija: atención bajo demanda y exclusión del tiempo de espera prometido.

Lo que estos datos no permiten afirmar

- Cubren enero a junio de 2016 y solo taxi amarillo: no hay invierno completo ni servicios por aplicación, que son el competidor real de UrbanMove.
- No hay tarifa, clima ni eventos. La recomendación de precio se sostiene en minutos por kilómetro, no en ingresos observados.
- La distancia es geodésica en línea recta sobre el elipsoide WGS84 y subestima el recorrido real, sobre todo en los viajes cortos.
- Los festivos son el 1,9 % de los viajes: las conclusiones sobre ellos tienen menos respaldo.
- La mezcla asume componentes gaussianas en el espacio transformado. El seno y el coseno de la hora solo toman 24 valores, así que una componente puede colapsar sobre una hora y disparar la verosimilitud: eso explica que el BIC no se estabilice dentro del rango probado y que con K = 6 la corrida aleatoria no converja. La velocidad es además función de duración y distancia; el efecto de quitarla está medido en la sección de sensibilidad. Modelar la hora con una distribución circular en lugar de seno y coseno gaussianos evitaría ese colapso.
- Las proporciones se calculan sobre muestras y no traen intervalo. Con 50.000 viajes el error estándar de una proporción es menor a 0,25 puntos porcentuales, así que las diferencias de más de un punto que se citan aquí no se explican por el muestreo.
- Siguiente paso: construir una rejilla espacial propia en lugar de los 237 barrios oficiales, que tienen tamaños muy desiguales, y cruzar la demanda con datos de clima.