

CONSULTORÍA PARA URBANMOVE

LO QUE EL PROMEDIO NO MOSTRABA

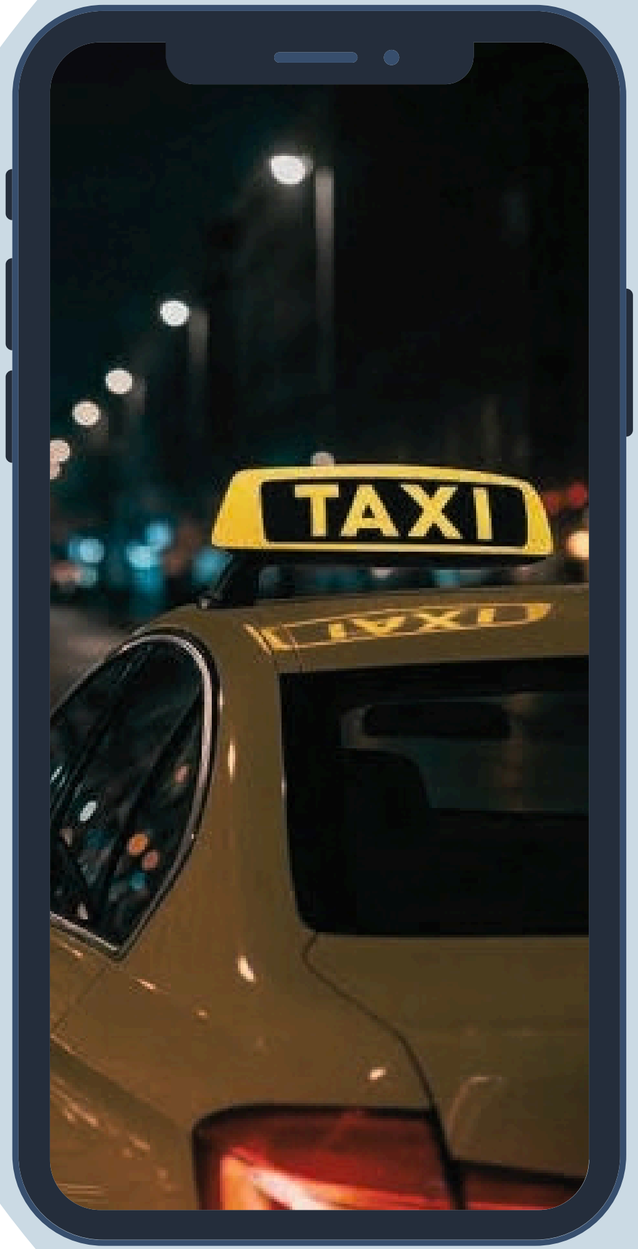
1.458.644 viajes de taxi en Nueva York

EL ENCARGO Y LOS DATOS QUE ENTRARON

UrbanMove pidió **números defendibles**, no un mapa de colores.

Las entropías y las divergencias se calculan sobre la base de trabajo completa, 1.431.173 viajes, porque son conteos y el costo es bajo. El clustering y la mezcla usan **50.000 viajes con semilla 2026**: la silueta crece al cuadrado y DBSCAN no cabe en memoria con 1,4 millones de puntos.

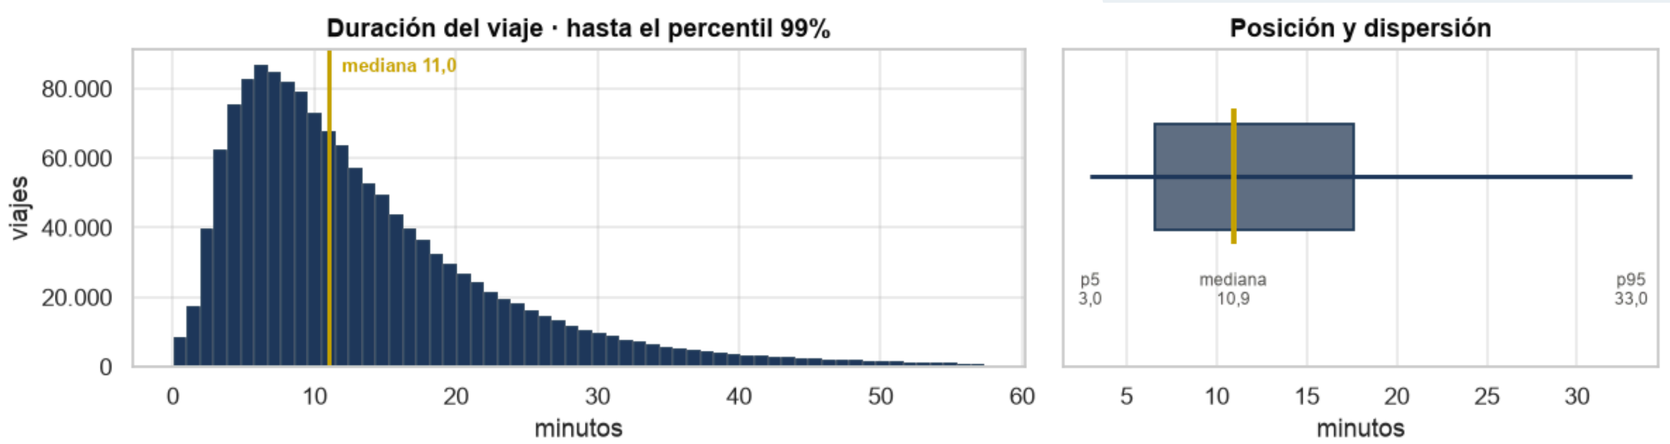
Antes de analizar **descartamos el 1,88% de los registros** con cinco reglas de calidad y pertinencia. Había viajes de 40 días y de 9.274 km/h. Ninguna regla se lleva más del 1,2%, así que la base sigue siendo la misma ciudad.



LO QUE EL PROMEDIO ESCONDE

DURACIÓN, VELOCIDAD Y DISTANCIA

La duración mediana es de 11 minutos y la media de 16: con asimetría de 343, **la media describe la cola y no al viaje típico**. La velocidad mediana es 12,8 km/h, con máximos imposibles de 9.274. Y la distancia tiene dos montículos: la ciudad cerca de 2 km y los aeropuertos cerca de 20.



n = 1.458.644 · media 15,99 · asimetría 343.2 · máximo 58.771,4 · fuera del eje: 14.575 viajes (1.00%)

DEL ARCHIVO CRUDO A LAS TRES DECISIONES

1. DATOS
1,46 M de viajes
Seis meses de 2016
Taxi amarillo de NYC

2. CALIDAD
5 reglas de calidad
Se cae el 1,88%
0 reglas pasan de 1,2%

3. INFORMACIÓN
H(zona) = 5,72 bits
IM del origen 7,7%
KL pico/madrugada 0,38

4. GEOMETRÍA
K-means con k = 4
DBSCAN, 7 núcleos
2,40% de ruido

5. MEZCLAS
GMM K = 3 por el codo del BIC
EM propio, 75 iteraciones
Certeza media 0,978

Los bloques 3, 4 y 5 **corren en paralelo** sobre la misma base limpia: cada rol aporta una evidencia distinta y las tres se juntan en la decisión.

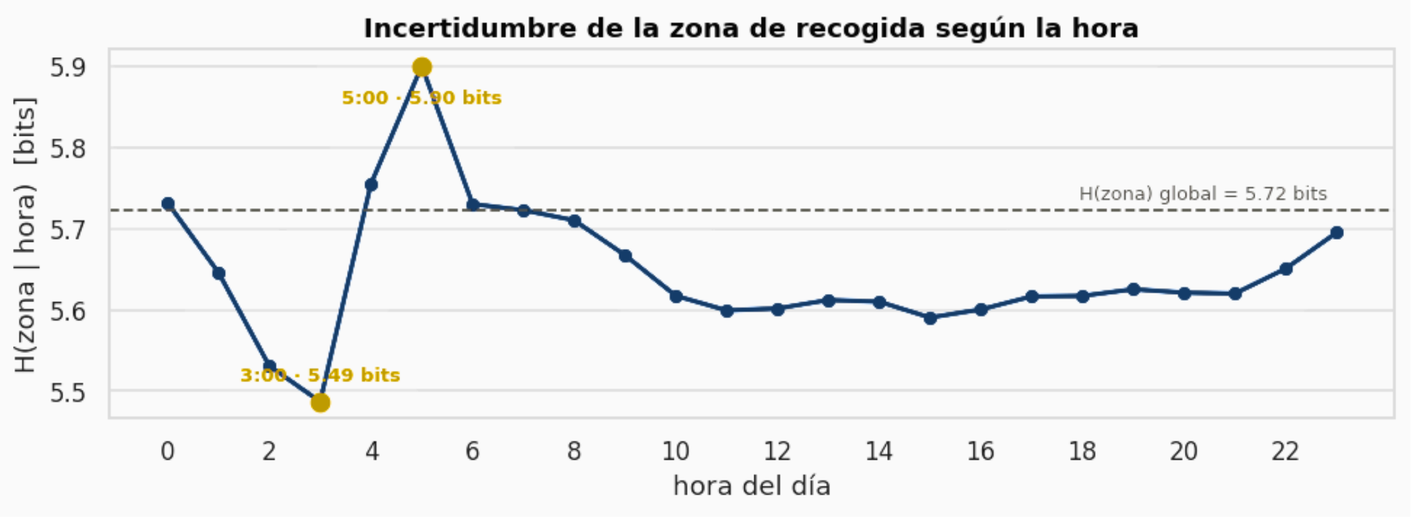
6. DECISIONES

Posicionar por zona y dimensionar por hora · Cobrar el tiempo en las horas atascadas · Reasignar flota de Midtown el fin de semana

Cada decisión cuelga de un número de los bloques de arriba, no de una impresión del mapa.

CUÁNTA INCERTIDUMBRE HAY

ENTROPÍA DE SHANNON SOBRE 1.431.173 VIAJES



5,72 BITS

Es la entropía de la **zona de recogida**. Si las 237 zonas tuvieran la misma demanda sería 7,89 bits.

53 ZONAS EFECTIVAS

2 elevado a 5,72. La ciudad se comporta como si tuviera **53 zonas con demanda pareja**, no 237.

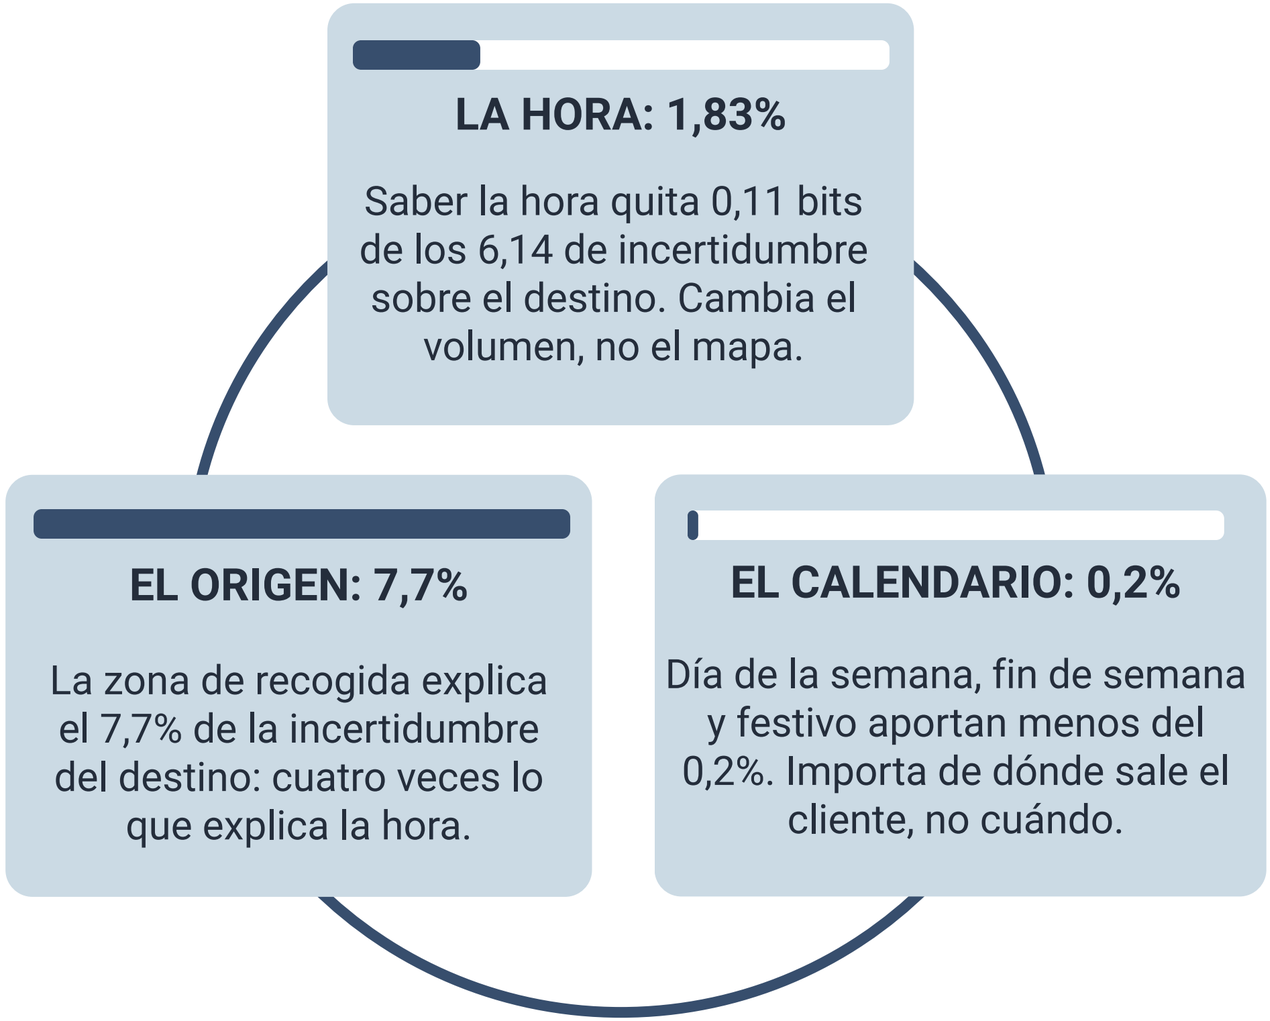
NI CUATRO PARADAS FIJAS

La demanda está **concentrada, pero no cabe en cuatro puntos**.

EL RELOJ NO DICE DÓNDE

INFORMACIÓN MUTUA CON LA ZONA DE DESTINO

Escala común: el largo de la barra es el porcentaje de la incertidumbre del destino que explica cada variable



DÓNDE SÍ CAMBIA EL MAPA

DIVERGENCIA KL ENTRE CONTEXTOS

Barra oscura: día laboral (o la KL entre días).
Barra celeste: fin de semana (o la KL entre pico y madrugada).

PICO CONTRA MADRUGADA: 0,38 BITS

Siete veces la diferencia entre día laboral y fin de semana, que es de 0,055. El contraste está entre horas, no entre días.

EAST VILLAGE: DE 2,65 A 4,70 %

Casi el doble de participación el fin de semana. Lower East Side sube de 1,19 a 2,69 %.

MIDTOWN BAJA 1,40 PUNTOS

La demanda **no desaparece: se muda** del distrito de oficinas a la zona de bares.

CUATRO POLOS DE DEMANDA

DURACIÓN, VELOCIDAD Y DISTANCIA

POR QUÉ NO K = 2

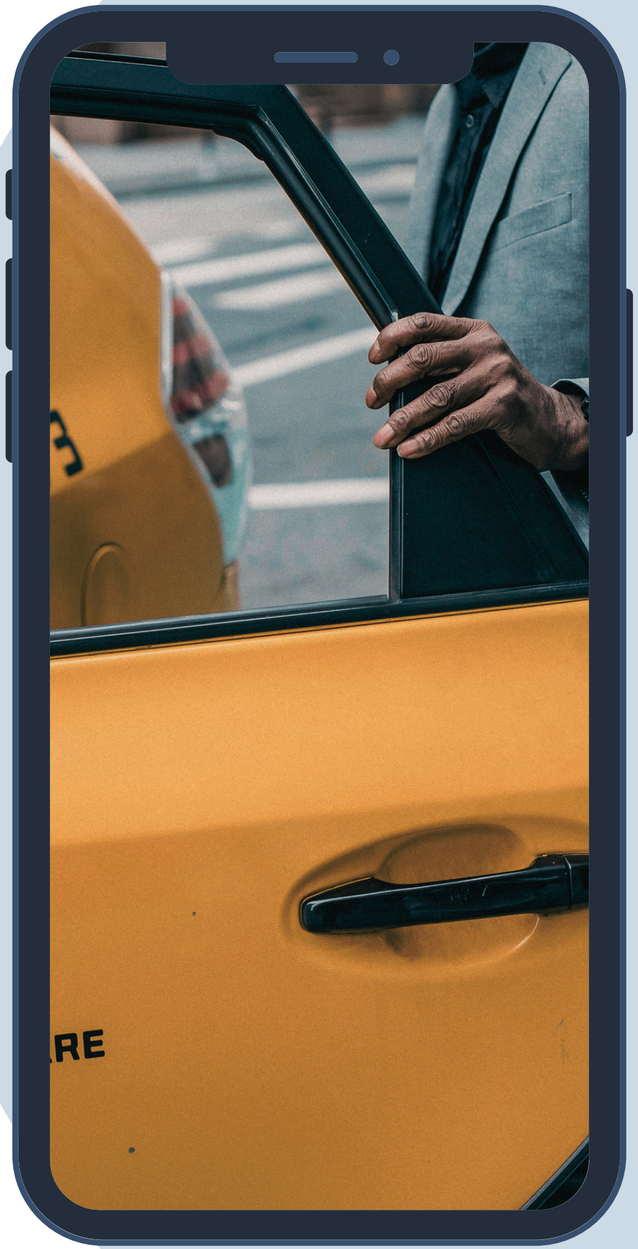
Tiene la mejor silueta, 0,808, pero solo separa Manhattan de los aeropuertos.

K = 4, SILUETA 0,496

Union Sq, Upper East Side South, LaGuardia y JFK. Es **donde el codo del SSE ya se aplanó**.

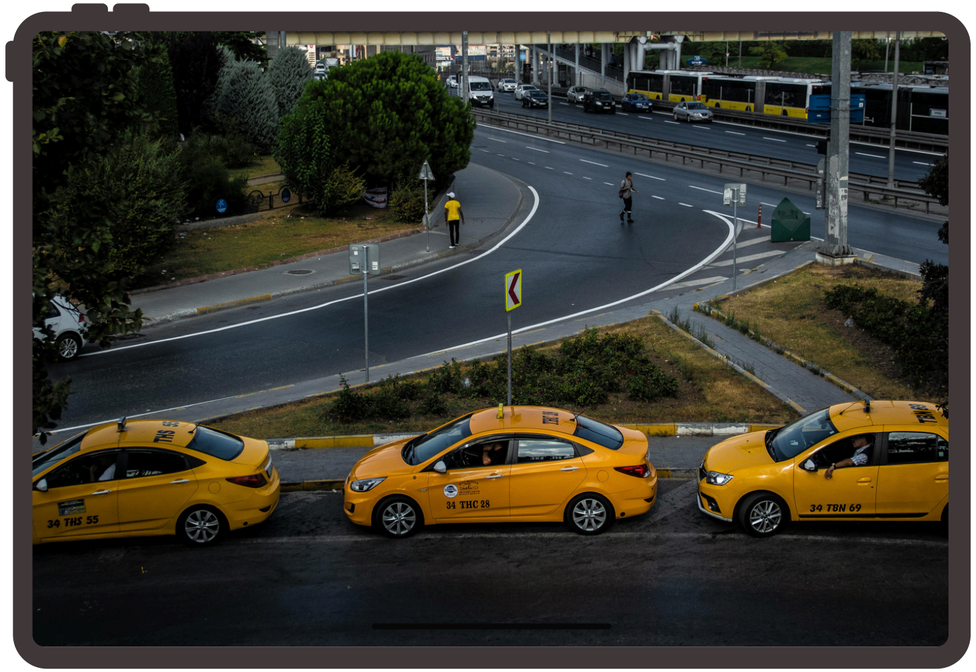
LOS AEROPUERTOS SON OTRO NEGOCIO

JFK: 38 minutos y 19,8 km de mediana, contra 10 minutos y 2 km en la ciudad. Con LaGuardia son el **5,4% de los viajes**.



EL 2 POR CIENTO QUE NO ENCAJA

DBSCAN CON EPS = 393 M Y MIN_SAMPLES = 50



SIETE NÚCLEOS DENSOS

El eps sale del codo real de la **curva de distancia al vecino 50**, no de un cuantil que fije el ruido de antemano.

2,40% DE RUIDO

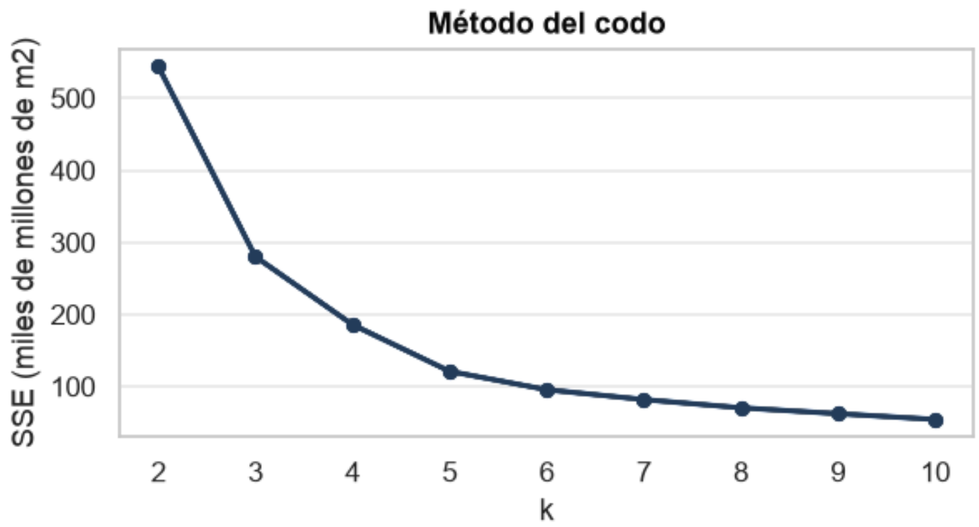
No es error: **son recogidas dispersas** con 3,1 km de mediana contra 2,1 del resto.

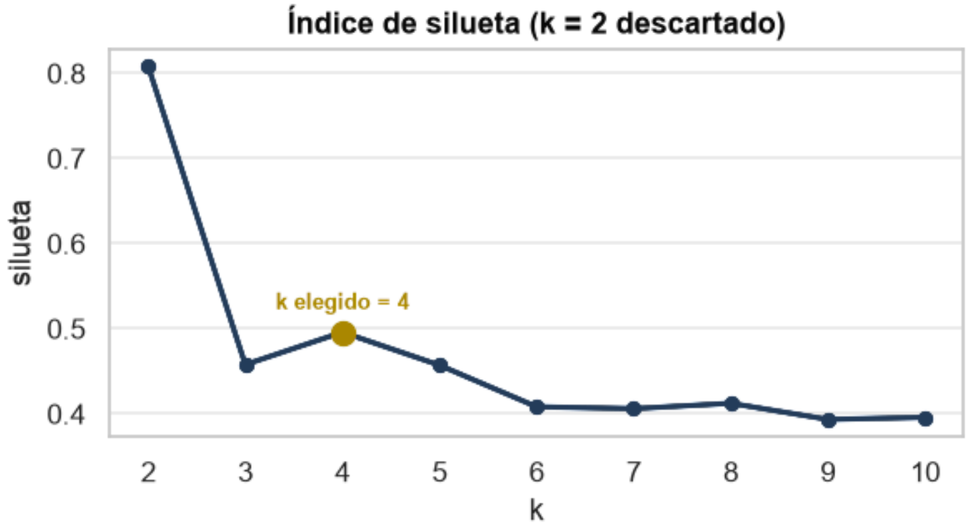
QUEENS 43%, BROOKLYN 38%

Ahí no debe haber flota estacionada: **atención bajo demanda** y fuera del tiempo de espera prometido.

CÓMO ELEGIMOS K Y EPS

Muestra de 50.000 viajes con semilla 2026 y coordenadas en metros.

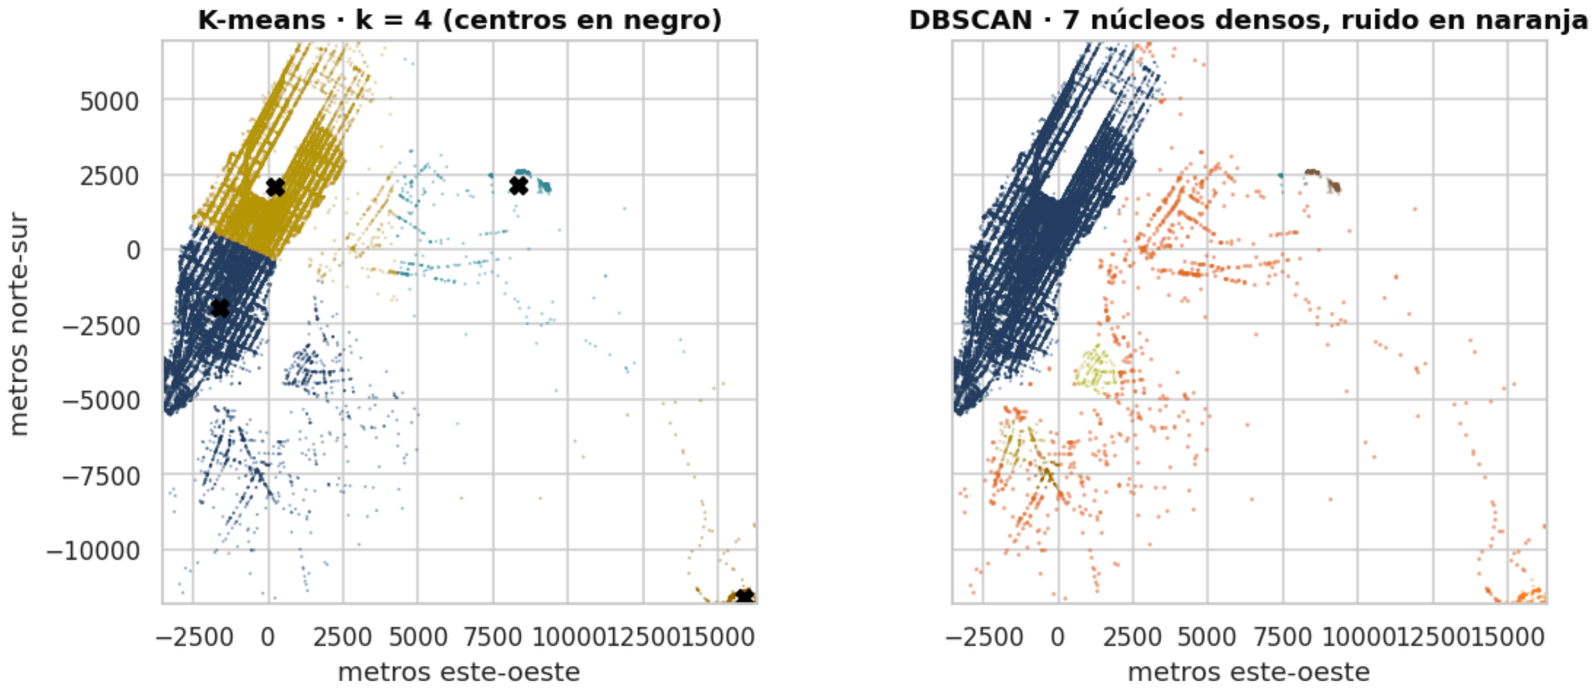




La silueta es máxima en k = 2, pero ahí solo se separa Manhattan de los aeropuertos. **Nos quedamos con k = 4:** es donde el codo del SSE ya se aplanó y los grupos sirven para mover flota.

K-MEANS CONTRA DBSCAN

Muestra de 50.000 viajes con semilla 2026 y coordenadas en metros.



K-means reparte toda la ciudad en **cuatro polos**. DBSCAN se queda con siete núcleos densos y manda el 2,40% a ruido: no compite con K-means, **responde otra pregunta**.

TRES PERFILES DE VIAJE

MEZCLA GAUSSIANA CON K = 3, ELEGIDO POR EL CODO DEL BIC



CÓMO SE AJUSTÓ

EM ESCRITO POR EL EQUIPO, CON SKLEARN SOLO COMO CONTROL



PASO E Y PASO M PROPIOS

El paso E **normaliza con log-sum-exp**, el mismo truco del bloque de información. Sin él, las densidades se van a cero.

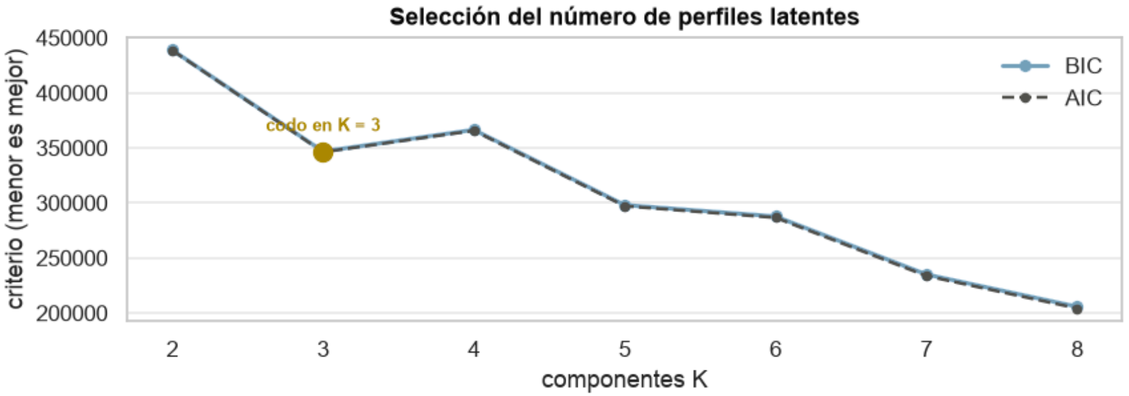
75 ITERACIONES

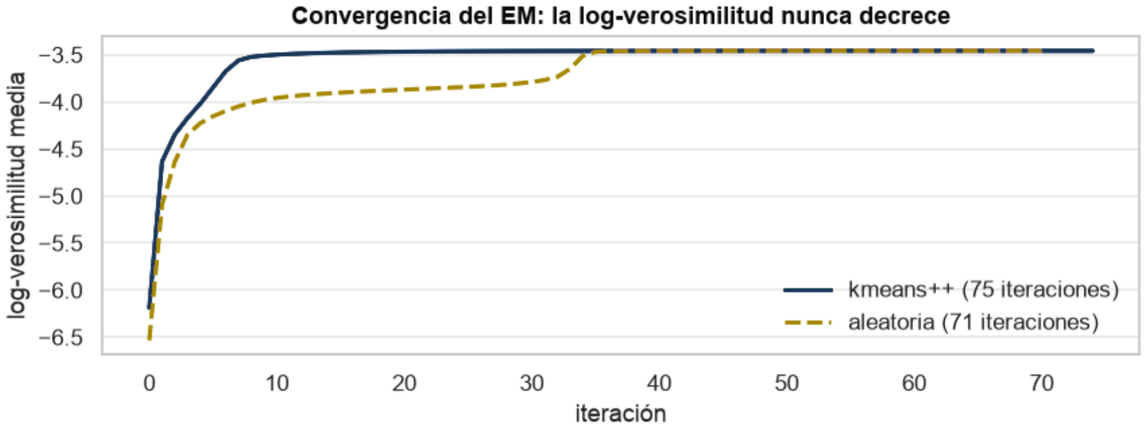
Log-verosimilitud de -3,459 contra -3,461 de sklearn. Certeza media de pertenencia 0,978 y solo 1,25% de viajes ambiguos.

EM NO GARANTIZA ÓPTIMO

Con K = 3, kmeans++ llega al mismo óptimo en las tres semillas; una corrida aleatoria quedó atrapada en -3,606. **Con K = 6 cambian ambas**.

POR QUÉ K = 3 Y CUÁNDO PARAMOS





EL BIC NO SE ESTABILIZA

Cae 21% hasta K = 3, repunta en K = 4 y sigue bajando hasta el borde del rango: un mínimo en el borde no es un mínimo. Nos quedamos en K = 3, que es mínimo local, codo de la curva y el último K con perfiles interpretables.

EL EM CONVERGE EN 75 PASOS

La log-verosimilitud sube en cada iteración, como tiene que ser, y **se aplana en -3,459 contra -3,461 de sklearn**. La diferencia está en el tercer decimal.

TRES DECISIONES PARA MAÑANA

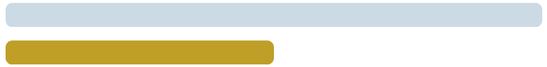
CADA UNA CON EL NÚMERO QUE LA SOSTIENE

POSICIONAR POR ZONA, DIMENSIONAR POR HORA

10 zonas concentran entre el 35 y el 42% de la demanda. Por hora, la madrugada mueve 27.868 viajes contra 72.972 de la tarde: **cambia el tamaño de la flota, no su ubicación**.

COBRAR EL TIEMPO EN LAS HORAS ATASCADAS

El 30,1% de los viajes gasta 7,80 minutos por km contra 3,86 del resto: 2,02 veces. **En día laboral, a las 11 a.m. son el 51,7%**.



7,80 min/km bajo 10 km/h · 3,86 min/km el resto

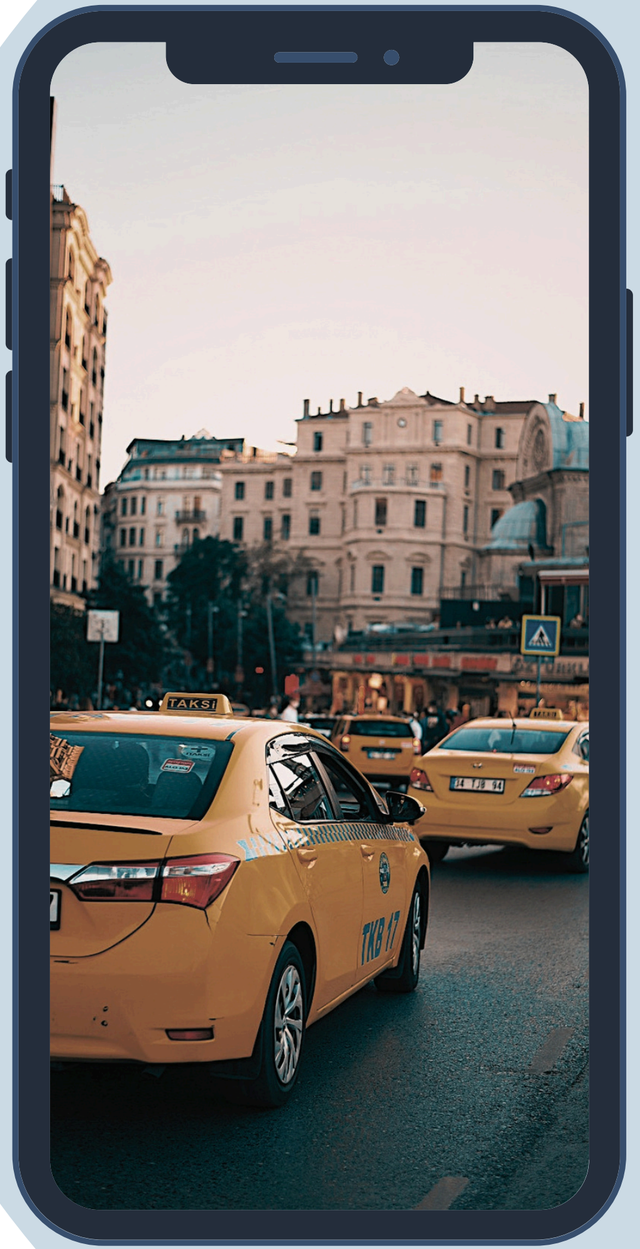
REASIGNAR EL FIN DE SEMANA

Mover **cerca de un tercio de la flota de Midtown** hacia East Village, Lower East Side y West Village. Brooklyn y Queens, **bajo demanda**.

QUÉ NO PODEMOS AFIRMAR

LÍMITES DEL ESTUDIO Y SIGUIENTE PASO

Son seis meses de 2016 y solo taxi amarillo: sin tarifa, sin clima y sin los servicios por aplicación, que son el competidor real. La distancia es en línea recta, así que **subestima el recorrido**. Lo siguiente sería pedir precio y clima, y **repetir el análisis con una rejilla espacial propia** en vez de los 237 barrios oficiales, que tienen tamaños muy desiguales.



GRACIAS

EQUIPO CONSULTOR:

- Ricardo Andrés Borja
- Gabriel Arturo Murillo
- Samuel Robayo
- María Andrea Torres